

Modelos Baseline Avançados e Engenharia de Atributos Temporais

Autores: Aevertton Santos de Oliveira
Caio Victor Lopes Serra
Carlos Henrique Santos de Carvalho
Fernando Gustavo
Jonatas de Jesus Souza
Maciel Lopes Francisco

Agenda

O objetivo desta apresentação é exibir a evolução do projeto MecâniQA, demonstrando a implementação de modelos baseline avançados, a criação de atributos temporais, a validação temporal e a comparação dos resultados obtidos por meio das métricas MAE, RMSE e MAPE.

1. Contexto:

Cenário da oficina e desafio de demanda.

2. Modelos Baseline Avançados:

Implementação dos modelos Naive e Médias Móveis.

3. Engenharia de Atributos Temporais:

Criação de Lags e Janelas Rolantes para previsão da demanda.

4. Validação Temporal:

Aplicação do TimeSeriesSplit para respeitar a ordem cronológica dos dados.

5. Prevenção de Erros no Modelo:

Cuidados contra Data Leakage e Overfitting durante o treinamento.

6. Avaliação dos Resultados:

Comparação dos modelos utilizando MAE, RMSE e MAPE.

Contexto



- A oficina MecâniQA gerencia atendimentos diários de manutenção e troca de óleo automotivo.
- O problema é a flutuação imprevisível da demanda de serviços, gerando oscilações acentuadas entre os dias da semana.
- O objetivo é evitar rupturas de estoque de insumos e ociosidade de equipe através de previsões preditivas em séries temporais.

Modelos Baseline Avançados



- Foram implementados e comparados dois modelos de referência para previsão da demanda:
- **Modelo Naive**
- **Médias Móveis**
- A comparação permite identificar qual abordagem representa melhor o comportamento da demanda de manutenções da MecâniQA.

Comparativo dos Modelos Baseline

Análise do Gráfico (90 dias):


Modelo Naive (Linha Laranja):

Acompanha a volatilidade e os picos de demanda com defasagem de 1 dia.

Média Móvel 7 Dias (Linha Verde):

Suaviza demais a curva e atrasa a reação aos picos reais.

O Naive captura melhor o padrão real do histórico de trocas de óleo.



- **Lags (1 e 7 dias):**

Lag 1: Pega o valor do dia anterior (captura a demanda imediata).

Lag 7: Pega o valor do mesmo dia da semana passada (captura o padrão semanal).

Janelas Rolantes:

Calcula a média e a variação dos últimos 7 dias para identificar tendências de alta ou baixa.

- **Objetivo Técnico:**

Enriquecimento dos Dados:

Transforma datas em sinais úteis para o algoritmo aprender padrões.

Sem Vazamento de Dados (*Data Leakage*): Todos os atributos usam apenas informações do passado em relação ao dia previsto.

Validação Temporal (TimeSeriesSplit)



- **O Desafio (Por que não usar K-Fold comum?)**

Em séries temporais, os dados dependem do tempo.

Não podemos usar dados do futuro para prever o passado (K-Fold tradicional embaralha tudo e estraga o teste).

- **O modelo treina com o passado e testa no período imediatamente seguinte.**

Validação Progressiva:

- **Fold 1:** Treina em Mês 1 → Testa em Mês 2
- **Fold 2:** Treina em Mês 1 + 2 → Testa em Mês 3
- **Fold 3:** Treina em Mês 1 + 2 + 3 → Testa em Mês 4

Prevenção de Erros no Modelo



- • **Evitar Data Leakage**

- Desfasamento de Dados (.shift(1)):**

- A previsão para o dia de hoje utiliza estritamente informações do dia anterior ($t - 1$).

- Garantia de que nenhuma informação do futuro entra no treino.

- **Evitar Overfitting**

- A escolha de modelos como o *Naive* evita memorizar ruídos e oscilações do histórico.

- Validação por Janelas:** Testes progressivos confirmam se o modelo generaliza bem para novos dias.

Avaliação dos Resultados (Métricas)



Tabela Comparativa:

Modelo	MAE (Erro Absoluto)	Desempenho
Naive (Ontem)	6,65 L/dia	Vencedor
Média Móvel (7 dias)	Superior a 8 L/dia	Perde picos de procura

Conclusões:

O modelo **Naive** obteve o menor erro médio diário (**MAE de 6,65 L/dia**).

Comportamento da Média Móvel:

Suavizou excessivamente os dados e atrasou a reação aos dias de pico.

Considerações finais



- **Baseline de Referência:** O modelo **Naive** obteve o melhor desempenho na série temporal, estabelecendo um erro médio absoluto de **6,65 L/dia**.
- **Atributos Temporais Criados:** Implementação concluída de **Lags (1 e 7)** e **Janela Rolante (7d)** para capturar a sazonalidade das oficinas.
- **Validação e Prevenção de Leakage:** Refatoração do treino/teste com **TimeSeriesSplit** e desfasamento `.shift(1)`, isolando totalmente os dados do futuro.

Referências

- **HYNDMAN, R. J., & ATHANASOPOULOS, G.** *Forecasting: Principles and Practice*. 3. ed. Melbourne: OTexts, 2021. (*Fundamentação de Modelos Baseline, Naive, Médias Móveis e Prevenção de Data Leakage em Séries Temporais*).
- **MCKINNEY, Wes.** *Python para Análise de Dados: Tratamento de Dados com Pandas, NumPy e Jupyter*. 2. ed. São Paulo: Novatec, 2018. (*Técnicas de Feature Engineering Temporal: criação de Defasagens com .shift() e Janelas Rolantes com .rolling()*).
- **KAUFMAN, S. et al.** *Leakage in Data Mining: Formulation, Detection, and Avoidance*. ACM Transactions on Knowledge Discovery from Data, 2012. (*Conceitos de isolamento de informação e prevenção de vazamento de dados do futuro*).