Centro Universitário de Excelência
Sistemas de Informação

Da previsão inicial à comprovação dos resultados

Autores: Aeverton Santos de Oliveira
Caio Victor Lopes Serra
Carlos Henrique Santos de Carvalho
Jonatas de Jesus Souza
Maciel Lopes Francisco
Fernando Gustavo Barbosa Santos

Itabuna, 2026

Agenda

O nosso objetivo é desenvolver modelos capazes de prever a demanda por trocas de óleo e avaliar se o aprendizado de máquina supera as previsões de referência.

1. Contexto:
Objetivo do projeto MecâniQA e previsão da demanda por manutenções.

2. Estrutura dos Dados:
Organização dos dados históricos e criação de variáveis para os modelos preditivos.

3. Análise da Série Temporal:
Comportamento da demanda e utilização de informações temporais nas previsões.

4. Pipeline de Machine Learning:
Treinamento dos modelos, otimização de hiperparâmetros e avaliação de desempenho.

5. Considerações Finais
Comparação dos resultados, ganhos obtidos e próximos passos do projeto.

Contexto do Problema

- Problema: oficinas automotivas enfrentam variações na demanda por manutenção, dificultando o planejamento de estoque e da equipe.
- Objetivo: utilizar dados históricos para prever a demanda por trocas de óleo e apoiar a tomada de decisões.
- Desafio da OAT 3: desenvolver, otimizar e avaliar modelos de Machine Learning, comparando seus resultados com um baseline.



Estrutura dos Dados

- Importação do histórico de manutenções em formato CSV e organização cronológica dos registros pela coluna `Data`.
- Criação de variáveis temporais: `lag_1`, `lag_7` e `mm_7` e definição das variáveis de entrada e do alvo `Trocas_Oleo` para o treinamento dos modelos.

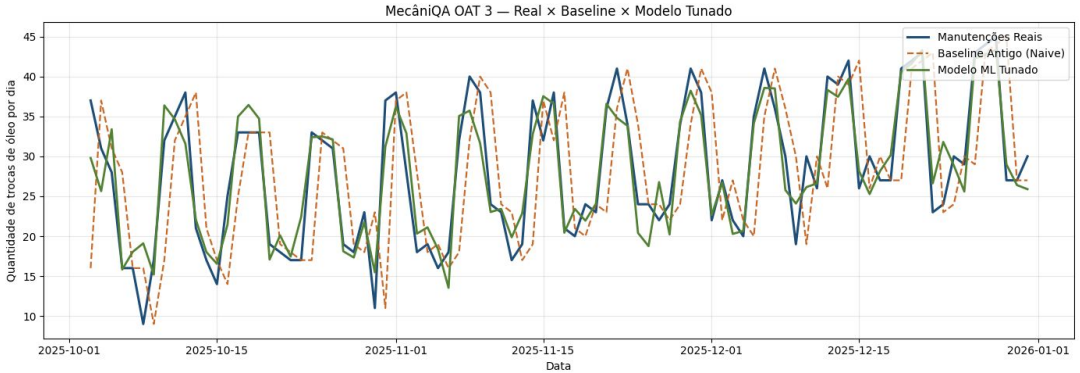
```
# 2. Criar as variáveis temporais
df["lag_1"] = df["Trocas_Oleo"].shift(1)
df["lag_7"] = df["Trocas_Oleo"].shift(7)
df["mm_7"] = df["Trocas_Oleo"].shift(1).rolling(window=7).mean()

# 3. Remover linhas sem histórico suficiente
df = df.dropna(subset=["lag_1", "lag_7", "mm_7", "Trocas_Oleo"])

# 4. Definir as variáveis de entrada e o alvo
features = ["lag_1", "lag_7", "mm_7", "Manutencao_Motor"]
X = df[features]
y = df["Trocas_Oleo"]
```

Análise da Série Temporal

- Análise do histórico de trocas de óleo ao longo do tempo.
- Identificação de tendências e padrões de sazonalidade.
- Utilização de informações temporais para apoiar as previsões de demanda.
- Preparação da base para o desenvolvimento dos modelos preditivos.



MecâniQA

Pipeline de Machine Learning

- Modelagem: treinamento inicial do Random Forest.
- Otimização: ajuste de hiperparâmetros com Grid Search.
- Comparação: análise entre Grid Search e Random Search.
- Validação: avaliação temporal com 5 folds.
- Métricas: MAE, RMSE e MAPE.

```
=== Comparação final no conjunto de teste ===
```

	MAE (trocas/dia)	RMSE (trocas/dia)	MAPE (%)	Tempo (segundos)
Grid Search	3.082	3.9	13.941	66.467
Random Search	3.082	3.9	13.941	12.130

Considerações finais

- Melhoria na previsão: o Random Forest tunado reduziu o MAE em relação ao baseline.
- Otimização eficiente: o Random Search alcançou métricas equivalentes às do Grid Search em menos tempo.
- Validação temporal: os modelos foram avaliados respeitando a ordem cronológica dos dados.
- Próximos passos: testar novos dados e avaliar a aplicação das previsões no planejamento de estoque e equipe.



Referências

- Pandas — documentação oficial: leitura de arquivos CSV, manipulação de DataFrames, conversão de datas e organização de dados temporais.
- Scikit-learn — documentação oficial: construção de modelos de Machine Learning, uso do Random Forest, otimização de hiperparâmetros com Grid Search e Random Search e avaliação por validação cruzada temporal.
- Scikit-learn — métricas de avaliação: documentação das métricas MAE, RMSE e MAPE para avaliar o erro das previsões dos modelos de regressão.
- Statsmodels — documentação oficial: decomposição de séries temporais com seasonal_decompose, incluindo componentes de tendência, sazonalidade e resíduo, nos modelos aditivo e multiplicativo.